

控制部分大作业二

轮腿机器人姿态与运动控制对比研究

基于局部线性化 LQR、降阶 WBC/QP 与 PPO 的固定场景对比及
鲁棒性初步讨论

学生：冯海燕、陈奕帆

日期：2026 年 6 月

课程控制大作业报告

摘要

本文研究竖直平面内轮腿机器人的速度跟踪与姿态稳定问题。题目给定躯干质量为 50 kg，大腿和小腿长度均为 0.5 m，轮半径为 0.1 m，可控制轮毂、膝关节和髋关节三路力矩；机器人需在 0 m/s–5 m/s 的速度范围内抵抗不平整地形和不超过 100 N 的水平质心扰动力。

为比较不同控制思想，本文在同一套二维降阶仿真模型上实现五种控制器：局部线性化 LQR、带显式动力学与约束的降阶 WBC/QP、基于 PD 稳定器的残差 PPO、仅保留模型前馈项的残差 PPO 消融方案，以及直接输出三路力矩的 PPO。实验包含八个主固定场景，每种实现各运行一次，共得到 40 条确定性轨迹。评价指标包括安全终止状态、高度与姿态误差、速度误差、稳态速度误差、力矩饱和比例以及平顺性和控制量代理指标。因此，本文的“鲁棒性”含义限定为固定扰动场景下的初步对比和有效性边界讨论，而非多随机种子 Monte Carlo 意义上的统计鲁棒性证明。

统一评估结果显示：五种实现均未触发报告设定的安全终止阈值。降阶 WBC/QP 的八场景平均高度 RMSE 为 3.8×10^{-4} m，平均姿态 RMSE 为 0.0095° ，平均速度 RMSE 为 0.258 m/s，在平台稳定性和综合速度指标上表现最稳。PD 残差 PPO 在相同 1.5×10^6 步训练协议下的平均姿态 RMSE 为 0.233° ，平均速度 RMSE 为 0.428 m/s；前馈残差消融方案平均速度 RMSE 为 2.053 m/s，说明去掉基础反馈后速度性能明显下降。直接力矩 PPO 在同一训练预算、学习率、熵系数和动作惩罚下保持了较小高度与姿态误差，但平均速度 RMSE 达到 6.572 m/s，表明直接力矩动作空间本身并不天然带来更好的速度跟踪。

此外，因为 WBC/QP 与前向仿真共享同一降阶模型和精确地形信息，仿真未加入参数失配、传感器噪声、时延和复杂离地碰撞。本文还设置了 0 m/s 静止抗扰检查，并据此给出控制器适用范围、实验有效性边界和后续改进方向。

关键词：轮腿机器人；LQR；全身控制；二次规划；PPO；固定场景对比

目录

摘要 I

1 题目要求与研究范围 1

1.1 题目要求 1

1.2 研究路线与控制器分组 1

1.3 参数设定 2

2 二维降阶仿真模型 4

2.1 状态、输入与地形 4

2.2 轮腿几何与可达性 4

2.3 力矩限幅与接触力 4

2.4 前向动力学与积分 5

2.5 安全终止判据 6

3 评价指标 6

3.1 轨迹日志 6

3.2 核心指标 6

4 局部线性化 LQR 7

4.1 方法特点 7

4.2 方法实现 8

5 降阶 WBC/QP 控制器 9

5.1 方法特点 9

5.2 决策变量与任务目标 9

5.3 动力学等式约束 9

5.4 不等式约束与预测边界 10

5.5 二次规划目标与求解 11

6 PPO 强化学习控制 11

6.1 方法特点 11

6.2 环境观测与奖励 11

6.3 PD 残差 PPO 12

6.4 前馈残差 PPO 13

6.5 直接力矩 PPO 13

6.6	训练配置	13
7	固定场景与数据来源	14
7.1	八个主固定场景	14
7.2	数据来源与图表说明	15
8	总体结果与有效性分析	15
8.1	八场景汇总	15
8.2	PPO 受控训练协议比较	16
9	分场景结果分析	17
9.1	场景 A: 瞬态强冲击	17
9.2	场景 B: 持续恒定推力	19
9.3	场景 C1: 规则正弦地形	21
9.4	场景 C2: 平滑随机地形	22
9.5	场景 D: 大幅不规则地形	23
9.6	场景 E: 超规格组合压力	25
9.7	场景 F: 5m/s 高速平地	28
9.8	场景 G: 题目边界组合	29
9.9	场景 H: 0m/s 静止抗扰	30
10	控制器比较与实现改进	31
10.1	LQR	31
10.2	降阶 WBC/QP	31
10.3	残差 PPO 与直接 PPO	31
10.4	推荐方案	31
11	复现方式与代码核验清单	32
11.1	依赖安装	32
11.2	建议的统一评估命令	32
11.3	受控 PPO 训练命令	32
11.4	静止抗扰与回归测试入口	33
11.5	主要源码映射	33
12	结论	34
	参考文献	34

1 题目要求与研究范围

1.1 题目要求

研究对象为竖直平面内运动的轮腿机器人，如图 1 所示。机器人具有三路可控输入：轮毂力矩 τ_{wheel} 、膝关节力矩 τ_{knee} 和髋关节力矩 τ_{hip} 。题目给定躯干质量、大腿长度、小腿长度和轮半径，并要求机器人在 0 m/s – 5 m/s 速度范围内跟踪水平速度指令，同时承受不平整地形和作用于躯干质心处、幅值不超过 100 N 的水平扰动力。

本文将题目目标写成三个受控量：水平速度 v_x 跟踪指令 v_{cmd} ，躯干俯仰角 θ 跟踪零姿态，髋部绝对高度 y 跟踪参考高度 y_{ref} 。三路力矩统一经过限幅后进入同一个二维前向仿真模型，由同一组评价指标统计高度、姿态、速度和控制量表现。




图 1: 题目给出的轮腿机器人示意图。本文把水平外力作为通过躯干质心的平动力处理。

1.2 研究路线与控制器分组

轮腿机器人兼具轮式移动效率和腿式地形适应能力，相关系统常将任务空间控制、全身约束优化和学习控制结合起来实现稳定运动 [1]。本文在同一仿真平台上实现五种控制器：局部线性化 LQR、降阶 WBC/QP、PD 残差 PPO、前馈残差 PPO 和直接力矩 PPO。其中 LQR 作为模型反馈基线，WBC/QP 作为约束优化控制器，三种 PPO 用于比较不同学习控制结构。

统一仿真流程为：固定场景给出地形、速度指令和水平外力；控制器根据其观测信息输出 $[\tau_{\text{wheel}}, \tau_{\text{knee}}, \tau_{\text{hip}}]^T$ ；动力学模块对力矩限幅后计算接触力和状态导数；四阶 Runge-Kutta 积分推进状态；日志模块保存轨迹；评价模块输出指标。各控制器共享被控对象、仿真步长、执行器限幅、安全判据和测试场景。实现层面的观测信息为：LQR 使用状态

和速度指令，WBC/QP 使用当前地形并在预测约束中查询短时前方地形，PPO 使用由状态和局部地形高度、坡度组成的观测向量。

需要强调的是，本文研究对象是题目参数驱动的二维降阶轮腿模型，而不是含真实髋膝关节角、轮速、连杆质量、转动惯量和接触切换的完整多刚体机器人模型。报告中的控制器优劣结论只针对该降阶模型、参数、限幅和场景成立。

1.3 参数设定

表 1 汇总代码中使用的主要机器人参数、仿真参数和控制器动作尺度。

表 1: 机器人与仿真参数

参数	符号	数值	来源或作用
躯干质量	m	50 kg	题目给定
大腿长度	L_1	0.5 m	题目给定
小腿长度	L_2	0.5 m	题目给定
轮半径	r	0.1 m	题目给定
重力加速度	g	9.81 m/s ²	常规取值
躯干等效转动惯量	I	5.0 kg m ²	降阶模型设定
轮地摩擦系数	μ	0.8	接触模型设定
期望髋部高度	y_{ref}	0.82 m	统一测试参考值
腿部平衡长度	l_0	0.72 m	被动支撑模型设定
腿部等效刚度	k_l	900 N/m	被动支撑模型设定
腿部等效阻尼	c_l	55 N s/m	被动支撑模型设定
水平阻尼系数	c_x	10.0	水平速度阻尼
竖直阻尼系数	c_y	35.0	竖直速度阻尼
姿态等效刚度	k_θ	18.0	躯干俯仰回复项
姿态等效阻尼	c_θ	2.8	躯干角速度阻尼
腿部等效力臂	d	0.25 m	髋部力矩到竖直支撑力的映射
俯仰耦合比例	γ	0.25	切向接触力到躯干俯仰的等效传递比例
仿真步长	Δt	0.01 s	100 Hz 控制周期
单次时长	T	8 s	固定场景时长
高度失败阈值	h_{fail}	0.15 m	髋部高度安全判据
最小腿长阈值	l_{safety}	0.18 m	腿部塌缩安全判据
力矩上限	τ_{max}	[30, 160, 120] ^T N m	轮、膝、髋三路人为限幅
残差动作尺度	s_{res}	[5, 25, 25] ^T N m	PD 残差 PPO 使用

注：质量、腿长和轮半径来自题目，其余参数由仿真模型和控制器实现统一给定。

2 二维降阶仿真模型

2.1 状态、输入与地形

仿真状态取髋部平动、躯干俯仰及其速度：

$$\mathbf{x} = [x, y, \theta, v_x, v_y, \omega]^\top, \quad (1)$$

$$\boldsymbol{\tau} = [\tau_{\text{wheel}}, \tau_{\text{knee}}, \tau_{\text{hip}}]^\top. \quad (2)$$

其中 x, y 为髋部位置, θ 为躯干俯仰角, v_x, v_y 为髋部速度, ω 为俯仰角速度。地形对象统一提供高度 $h(x)$ 、坡度 $h'(x)$ 和曲率 $h''(x)$ 。平地直接给出零高度和零坡度；正弦地形采用解析导数；多频地形把多个正弦分量叠加后按最大高度缩放；随机地形先采样高斯高度, 再用卷积平滑和三次样条生成连续高度、坡度和曲率。该状态没有显式关节角、轮速、连杆姿态和接触模式, 因此更接近带轮式水平驱动的竖直伸缩腿模型；大腿和小腿长度主要用于腿长可达性和观测量构造。

2.2 轮腿几何与可达性

轮心高度由地形高度和轮半径给出：

$$y_{\text{wheel}} = h(x) + r. \quad (3)$$

代码把两段腿的支撑效果写成竖直伸缩腿, 腿长和腿长变化率为

$$l = y - y_{\text{wheel}} = y - h(x) - r, \quad (4)$$

$$\dot{l} = v_y - h'(x)v_x. \quad (5)$$

逆运动学函数用两连杆长度检查该腿长是否可达。设两段长度为 L_1, L_2 , 内部膝角满足

$$\cos \beta_{\text{int}} = \frac{L_1^2 + L_2^2 - l_c^2}{2L_1L_2}, \quad (6)$$

其中 l_c 是裁剪到 $(0, L_1 + L_2)$ 内的腿长。代码定义膝屈曲角

$$\beta_{\text{knee}} = \pi - \beta_{\text{int}}, \quad (7)$$

并取

$$q_{\text{hip}} = \frac{1}{2}\beta_{\text{knee}}. \quad (8)$$

这两个角度用于构造腿部几何量和 PPO 观测, 安全判定使用原始腿长 l 的可达性。

2.3 力矩限幅与接触力

所有控制器输出先经过统一执行器限幅：

$$\boldsymbol{\tau} = \text{clip}(\boldsymbol{\tau}_{\text{cmd}}, -\boldsymbol{\tau}_{\text{max}}, \boldsymbol{\tau}_{\text{max}}). \quad (9)$$

膝关节和髋关节力矩通过等效力臂 $d = 0.25 \text{ m}$ 形成主动腿部支撑力:

$$F_{\text{leg,act}} = \frac{\tau_{\text{knee}} + 0.6\tau_{\text{hip}}}{d}, \quad (10)$$

$$F_{\text{leg,pass}} = k_l(l_0 - l) - c_l \dot{l}, \quad (11)$$

$$F_{\text{leg}} = F_{\text{leg,act}} + F_{\text{leg,pass}}. \quad (12)$$

轮毂力矩形成期望切向驱动力

$$F_{\text{drive,cmd}} = \frac{\tau_{\text{wheel}}}{r}. \quad (13)$$

接触法向力和切向力按

$$F_n = \max(F_{\text{leg}}, 0), \quad (14)$$

$$F_t = \text{clip}(F_{\text{drive,cmd}}, -\mu \max(F_n, 1), \mu \max(F_n, 1)) \quad (15)$$

计算。这里的切向力限幅对应二维库仑摩擦约束， $\max(F_n, 1)$ 用于法向力很小时的数值保护；它不是物理离地接触模型，只避免数值积分在 $F_n \approx 0$ 时出现零摩擦边界奇异。正式评估轨迹中腿长和法向力均未进入长期离地状态，因此该保护主要影响极端瞬态附近的数值稳定性。

2.4 前向动力学与积分

动力学模块把轮地切向力、腿部支撑力、阻尼、坡度阻力和外力合成为三个加速度:

$$\ddot{x} = \frac{F_t + F_{\text{ext}} - c_x v_x - mgh'(x)}{m}, \quad (16)$$

$$\ddot{y} = \frac{F_{\text{leg}} - mg - c_y v_y}{m}, \quad (17)$$

$$\ddot{\theta} = \frac{\tau_{\text{hip}} + 0.15\tau_{\text{knee}} + d_t F_t - k_\theta \theta - c_\theta \omega}{I}, \quad (18)$$

其中轮地切向力到躯干俯仰的等效力臂为

$$d_t = \gamma \max(y - h(x), 0.1). \quad (19)$$

因此状态导数为

$$\dot{\mathbf{x}} = [v_x, v_y, \omega, \ddot{x}, \ddot{y}, \ddot{\theta}]^\top. \quad (20)$$

上式采用小坡度等效处理： F_n 和 F_t 保留接触力解释，但在动力学中分别作为竖直支撑力和水平驱动力使用；坡度影响主要通过 $mgh'(x)$ 和腿长变化率进入。对于高坡度、大曲率或离地碰撞工况，该近似需要由地形坐标系力分解和多刚体接触模型替代。单步推进使用

四阶 Runge-Kutta:

$$\mathbf{k}_1 = f(\mathbf{x}_k, \tau_k), \quad (21)$$

$$\mathbf{k}_2 = f(\mathbf{x}_k + \frac{1}{2}\Delta t \mathbf{k}_1, \tau_k), \quad (22)$$

$$\mathbf{k}_3 = f(\mathbf{x}_k + \frac{1}{2}\Delta t \mathbf{k}_2, \tau_k), \quad (23)$$

$$\mathbf{k}_4 = f(\mathbf{x}_k + \Delta t \mathbf{k}_3, \tau_k), \quad (24)$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \frac{\Delta t}{6}(\mathbf{k}_1 + 2\mathbf{k}_2 + 2\mathbf{k}_3 + \mathbf{k}_4). \quad (25)$$

其中 $f(\mathbf{x}, \tau)$ 表示由前向动力学计算出的状态导数函数, $\mathbf{k}_1$ 至 $\mathbf{k}_4$ 是 Runge-Kutta 方法在一个步长内的四次斜率估计。日志中保存推进后状态对应的加速度、接触力、饱和状态和控制器诊断量。

2.5 安全终止判据

每个积分步后检查安全状态:

1. $|\theta| > 30^\circ$, 记为 `theta_fail`;
2. $|y - y_{\text{ref}}| > 0.15 \text{ m}$, 记为 `height_fail`;
3. 腿长超出 $r \leq l \leq L_1 + L_2$, 记为 `leg_infeasible`;
4. $l < 0.18 \text{ m}$, 记为 `leg_collapsed`.

若触发任一条件, 仿真记录失败原因; 默认评估在首次失败后停止。因此, 表格中的“未终止”仅表示未触发上述粗粒度失败条件, 并不等同于真实系统安全。当前判据尚未包含速度发散、长期力矩饱和、能耗过高、接触力异常或超出任务速度范围等更细的安全约束。

3 评价指标

3.1 轨迹日志

每次仿真保存从 $t = 0$ 到终止时刻的采样序列。日志包含状态、速度指令、参考高度、真实外力、地形高度与坡度、轮心高度、腿长、三路力矩、法向/切向接触力、三向加速度、饱和标志、失败标志以及 WBC/QP 诊断量。若场景完整运行 8 s, 在 $\Delta t = 0.01 \text{ s}$ 下共有 801 个采样点。

3.2 核心指标

设日志采样点数为 N , 评价模块首先根据失败原因定义

$$S = \begin{cases} 1, & \text{未记录失败原因,} \\ 0, & \text{记录了失败原因.} \end{cases} \quad (26)$$

高度、姿态和速度误差指标为

$$\text{RMSE}_h = \sqrt{\frac{1}{N} \sum_{k=1}^N (y_k - y_{\text{ref},k})^2}, \quad (27)$$

$$e_{h,\max} = \max_k |y_k - y_{\text{ref},k}|, \quad (28)$$

$$\text{RMSE}_\theta = \sqrt{\frac{1}{N} \sum_{k=1}^N \theta_k^2}, \quad (29)$$

$$\theta_{\max} = \max_k |\theta_k|, \quad (30)$$

$$\text{RMSE}_v = \sqrt{\frac{1}{N} \sum_{k=1}^N (v_{x,k} - v_{\text{cmd},k})^2}. \quad (31)$$

由于速度指令由零平滑上升到目标值，全时域速度 RMSE 会混入启动过程。作为稳态评价，本文还统计 $t \geq 2\text{ s}$ 后的速度误差：

$$\text{RMSE}_{v,\text{ss}} = \sqrt{\frac{1}{|\mathcal{I}_{\text{ss}}|} \sum_{k \in \mathcal{I}_{\text{ss}}} (v_{x,k} - v_{\text{cmd},k})^2}, \quad \mathcal{I}_{\text{ss}} = \{k : t_k \geq 2\text{ s}\}. \quad (32)$$

表格中的姿态 RMSE 和最大姿态角统一换算为角度。力矩饱和比例按三路力矩的全部采样元素统计：

$$\rho_{\text{sat}} = \frac{1}{3N} \sum_{k=1}^N \sum_{i=1}^3 \mathbf{1}\left(\frac{|\tau_{i,k}|}{\tau_{i,\max}} \geq 0.98\right). \quad (33)$$

同时，为避免三路执行器平均后掩盖具体瓶颈，报告列出分通道饱和比例

$$\rho_{\text{sat},i} = \frac{1}{N} \sum_{k=1}^N \mathbf{1}\left(\frac{|\tau_{i,k}|}{\tau_{i,\max}} \geq 0.98\right), \quad i \in \{\text{wheel}, \text{knee}, \text{hip}\}. \quad (34)$$

评价模块还计算水平加速度变化和平动/转动动态响应组成的平顺性代理量：

$$J_s = \int (\dot{a}_x^2 + 0.1\alpha^2) dt, \quad (35)$$

其中 $\alpha = \ddot{\theta}$ ， $\dot{a}_x$ 由离散梯度 `np.gradient` 计算。力矩平方积分为

$$E_\tau = \int (\tau_{\text{wheel}}^2 + \tau_{\text{knee}}^2 + \tau_{\text{hip}}^2) dt. \quad (36)$$

两个积分均由梯形积分实现。WBC/QP 轨迹额外统计 QP 成功比例、OSQP 成功比例、回退比例、平均迭代次数、平均/最大求解耗时、约束残差、摩擦利用率和安全松弛量。

4 局部线性化 LQR

4.1 方法特点

LQR 是经典线性二次型最优控制方法 [2, 3]。它先把非线性系统在工作点附近写成线性模型

$$\Delta \dot{\mathbf{x}} = A\Delta \mathbf{x} + B\Delta \boldsymbol{\tau}, \quad (37)$$

再最小化二次型性能指标

$$J = \int_0^\infty (\Delta \mathbf{x}^\top Q \Delta \mathbf{x} + \Delta \boldsymbol{\tau}^\top R \Delta \boldsymbol{\tau}) dt. \quad (38)$$

该方法控制律为线性状态反馈，结构清晰、在线计算量小，适合用作局部稳定控制基线；其控制性能由线性化工作点和权重矩阵共同决定。

4.2 方法实现

LQR 控制器在平地、无外力条件下按当前速度指令 v_{cmd} 构造名义状态

$$\mathbf{x}_0 = [0, y_{\text{ref}}, 0, v_{\text{cmd}}, 0, 0]^\top. \quad (39)$$

代码中的平衡力矩由 `equilibrium_torque` 给出。轮毂力矩抵消水平阻尼：

$$\tau_{\text{wheel},0} = c_x v_{\text{cmd}} r, \quad (40)$$

对应名义切向力 $F_{t,0} = c_x v_{\text{cmd}}$ 。膝、髋力矩由主动支撑力和俯仰力矩两个方程确定：

$$\begin{bmatrix} 1 & 0.6 \\ 0.15 & 1 \end{bmatrix} \begin{bmatrix} \tau_{\text{knee},0} \\ \tau_{\text{hip},0} \end{bmatrix} = \begin{bmatrix} dm g \\ -d_{t,0} F_{t,0} \end{bmatrix}, \quad (41)$$

其中

$$d_{t,0} = \gamma(l_0 + r). \quad (42)$$

在该工作点附近，代码用中心差分计算 A 和 B 。差分步长为 $\epsilon = 10^{-5}$ ：

$$A_{:,i} = \frac{f(\mathbf{x}_0 + \epsilon \mathbf{e}_i, \boldsymbol{\tau}_0) - f(\mathbf{x}_0 - \epsilon \mathbf{e}_i, \boldsymbol{\tau}_0)}{2\epsilon}, \quad (43)$$

$$B_{:,j} = \frac{f(\mathbf{x}_0, \boldsymbol{\tau}_0 + \epsilon \mathbf{e}_j) - f(\mathbf{x}_0, \boldsymbol{\tau}_0 - \epsilon \mathbf{e}_j)}{2\epsilon}. \quad (44)$$

其中 $f(\mathbf{x}, \boldsymbol{\tau})$ 为状态导数函数， $\mathbf{e}_i$ 和 $\mathbf{e}_j$ 分别为状态空间和输入空间中的单位基向量， ϵ 为中心差分扰动步长。状态权重和输入权重为

$$Q = \text{diag}(0, 600, 1800, 30, 120, 280), \quad (45)$$

$$R = \text{diag}(0.03, 0.06, 0.05). \quad (46)$$

连续代数 Riccati 方程

$$A^\top P + PA - PBR^{-1}B^\top P + Q = 0 \quad (47)$$

给出反馈矩阵

$$K = R^{-1}B^\top P. \quad (48)$$

其中 P 为 Riccati 方程的对称正定解， K 为用于在线反馈的状态增益矩阵。

在线控制时，参考状态取为

$$\mathbf{x}_{\text{ref}} = [x, y_{\text{ref}}, 0, v_{\text{cmd}}, 0, 0]^\top, \quad (49)$$

因此反馈误差为

$$\mathbf{x} - \mathbf{x}_{\text{ref}} = [0, y - y_{\text{ref}}, \theta, v_x - v_{\text{cmd}}, v_y, \omega]^T. \quad (50)$$

控制律为

$$\boldsymbol{\tau} = \text{clip}(\boldsymbol{\tau}_0 - K(\mathbf{x} - \mathbf{x}_{\text{ref}}), -\boldsymbol{\tau}_{\text{max}}, \boldsymbol{\tau}_{\text{max}}). \quad (51)$$

增益按照四舍五入到两位小数的速度指令缓存, 避免重复求解 Riccati 方程。

5 降阶 WBC/QP 控制器

5.1 方法特点

全身控制和操作空间控制把机器人任务、接触力、执行器力矩和物理约束放入统一控制框架 [4]。QP 形式的优点是任务目标和约束可以直接写入优化问题; 其在线计算由二次规划求解器完成, 适合表达摩擦、法向力、力矩边界和预测安全边界。本文模型已经把腿部几何降阶为竖直腿长, 因此控制器实现为降阶任务空间 WBC/QP。

5.2 决策变量与任务目标

每个控制周期的决策变量为

$$\mathbf{z} = [a_x, a_y, \alpha, F_t, F_n, \tau_{\text{wheel}}, \tau_{\text{knee}}, \tau_{\text{hip}}, s_{l,-}, s_{l,+}, s_{y,-}, s_{y,+}]^T. \quad (52)$$

前三项为任务空间加速度, F_t, F_n 为切向和法向接触力, 后三个力矩为控制输出, 四个松弛变量用于预测腿长和预测高度边界。

期望任务加速度由速度、高度和姿态误差给出:

$$e_{v,I} \leftarrow \text{clip}(e_{v,I} + \Delta t(v_{\text{cmd}} - v_x), -2, 2), \quad (53)$$

$$a_{x,\text{des}} = 5(v_{\text{cmd}} - v_x) + 2e_{v,I}, \quad (54)$$

$$a_{y,\text{des}} = 115(y_{\text{ref}} - y) - 24v_y, \quad (55)$$

$$\alpha_{\text{des}} = -125\theta - 24\omega. \quad (56)$$

其中 $e_{v,I}$ 为速度误差积分状态, 控制器重置时置零。

5.3 动力学等式约束

WBC/QP 使用与前向动力学一致的仿射模型。固定当前状态、地形和控制器可用外力估计 $\hat{F}_{\text{ext}}$ 后, 平动方程给出

$$ma_x - F_t = \hat{F}_{\text{ext}} - c_x v_x - mgh'(x), \quad (57)$$

$$ma_y - F_n = -mg - c_y v_y. \quad (58)$$

俯仰动力学写为

$$I\alpha - d_t F_t - 0.15\tau_{\text{knee}} - \tau_{\text{hip}} = -k_\theta \theta - c_\theta \omega, \quad (59)$$

其中 $d_t = \gamma \max(y - h(x), 0.1)$ 。轮毂力矩与切向力、膝髌力矩与法向力之间的执行器映射为

$$\tau_{\text{wheel}} - rF_t = 0, \quad (60)$$

$$\tau_{\text{knee}} + 0.6\tau_{\text{hip}} - dF_n = -dF_{\text{leg,pass}}, \quad (61)$$

其中

$$F_{\text{leg,pass}} = k_l(l_0 - l) - c_l \dot{l}. \quad (62)$$

其中 $\hat{F}_{\text{ext}}$ 表示控制器可用的水平外力估计量。正式评估默认不启用外力测量开关，因此控制器使用 $\hat{F}_{\text{ext}} = 0$ ；真实外力仍进入前向动力学。

5.4 不等式约束与预测边界

硬约束包括法向预载、摩擦锥、力矩边界和松弛变量非负：

$$F_n \geq 0.35mg, \quad (63)$$

$$F_t - \mu F_n \leq 0, \quad (64)$$

$$-F_t - \mu F_n \leq 0, \quad (65)$$

$$-\tau_{\text{max}} \leq \tau \leq \tau_{\text{max}}, \quad (66)$$

$$s_{l,-}, s_{l,+}, s_{y,-}, s_{y,+} \geq 0. \quad (67)$$

预测时域为 $T_p = 0.30 \text{ s}$ 。代码先以当前速度预瞄位置

$$x_p = x + T_p v_x \quad (68)$$

查询前方地形，并用待优化加速度修正未来高度和腿长：

$$y_p = y + T_p v_y + \frac{1}{2} T_p^2 a_y, \quad (69)$$

$$l_p = y + T_p v_y - h(x_p) - r + \frac{1}{2} T_p^2 a_y - \frac{1}{2} T_p^2 h'(x_p) a_x. \quad (70)$$

边界取

$$l_{\min} = l_{\text{safety}} + 0.02, \quad l_{\max} = L_1 + L_2 - 0.02, \quad (71)$$

$$y_{\min} = y_{\text{ref}} - h_{\text{fail}} + 0.01, \quad y_{\max} = y_{\text{ref}} + h_{\text{fail}} - 0.01. \quad (72)$$

预测约束写成

$$l_p + s_{l,-} \geq l_{\min}, \quad l_p - s_{l,+} \leq l_{\max}, \quad (73)$$

$$y_p + s_{y,-} \geq y_{\min}, \quad y_p - s_{y,+} \leq y_{\max}. \quad (74)$$

其中 l_{safety} 为安全判据中的最小腿长阈值， h_{fail} 为高度偏差失败阈值； $s_{l,-}, s_{l,+}$ 分别表示腿长下界和上界松弛量， $s_{y,-}, s_{y,+}$ 分别表示高度下界和上界松弛量。

5.5 二次规划目标与求解

目标函数采用加权二次型：

$$\begin{aligned} \min_z \quad & \frac{1}{2} \|\mathbf{a} - \mathbf{a}_{\text{des}}\|_{W_a}^2 + \frac{w_\tau}{2} \left\| \frac{\boldsymbol{\tau}}{\boldsymbol{\tau}_{\max}} \right\|_2^2 + \frac{w_{\Delta\tau}}{2} \left\| \frac{\boldsymbol{\tau} - \boldsymbol{\tau}_{\text{last}}}{\boldsymbol{\tau}_{\max}} \right\|_2^2 \\ & + \frac{w_f}{2} \left[\left(\frac{F_t}{\tau_{\text{wheel,max}}/r} \right)^2 + \left(\frac{F_n - mg}{mg} \right)^2 \right] + \frac{w_l}{2} (s_{l,-}^2 + s_{l,+}^2) + \frac{w_y}{2} (s_{y,-}^2 + s_{y,+}^2). \end{aligned} \quad (75)$$

代码中的权重为

$$W_a = \text{diag}(8, 180, 120), \quad (76)$$

$$w_\tau = 0.03, \quad w_{\Delta\tau} = 0.12, \quad w_f = 0.002, \quad w_l = 4 \times 10^5, \quad w_y = 6 \times 10^5. \quad (77)$$

问题被装配为 OSQP 标准形式

$$\min_z \frac{1}{2} \mathbf{z}^\top P \mathbf{z} + \mathbf{q}^\top \mathbf{z} \quad \text{s.t.} \quad \mathbf{l} \leq A \mathbf{z} \leq \mathbf{u}, \quad (78)$$

其中 P 和 $\mathbf{q}$ 分别为 QP 目标函数的 Hessian 矩阵和线性项， A 为等式、不等式和变量边界拼接后的约束矩阵， $\mathbf{l}, \mathbf{u}$ 为对应的下界和上界。并由 OSQP 求解 [5]。若候选解为非有限值、求解状态未成功，或等式/不等式残差超过阈值，控制器使用由稳定基线力矩构造的初始可行解。最终输出为 $\mathbf{z}$ 中三路力矩分量的限幅结果。

6 PPO 强化学习控制

6.1 方法特点

PPO 是基于策略梯度的强化学习算法，通过限制新旧策略概率比的变化幅度提高训练稳定性 [6]。在控制问题中，PPO 直接学习从观测 $\mathbf{o}$ 到动作 $\mathbf{u}$ 的非线性映射，适合表示难以手工线性化的反馈律；训练完成后，在线控制只需一次神经网络前向推理。本文通过 Gymnasium 环境接口和 Stable-Baselines3 完成训练与模型加载 [7, 8]。

6.2 环境观测与奖励

策略动作是三维归一化向量

$$\mathbf{u} = [u_1, u_2, u_3]^\top \in [-1, 1]^3. \quad (79)$$

观测向量由状态误差、腿长、局部地形和速度指令构成：

$$\mathbf{o} = [y - y_{\text{ref}}, \theta, v_x - v_{\text{cmd}}, v_y, \omega, l, h(x), h'(x), v_{\text{cmd}}]^\top. \quad (80)$$

训练环境重置时，初始状态在 $[0, y_{\text{ref}}, 0, 0, 0, 0]^\top$ 附近随机扰动：

$$y \leftarrow y_{\text{ref}} + \mathcal{N}(0, 0.01^2), \quad \theta \leftarrow \mathcal{N}(0, \deg(0.8)^2), \quad (81)$$

$$v_x \leftarrow \mathcal{N}(0, 0.04^2), \quad v_y \leftarrow \mathcal{N}(0, 0.02^2), \quad \omega \leftarrow \mathcal{N}(0, \deg(1.0)^2). \quad (82)$$

其中 $\mathcal{N}(\mu, \sigma^2)$ 表示均值为 μ 、方差为 σ^2 的高斯分布； $\deg(\cdot)$ 表示将角度值换算为弧度。

单步奖励由高度、姿态、速度、动作幅值、动态响应和终止状态组成：

$$r = 0.5 + 3.5e^{-130(y-y_{\text{ref}})^2} + 2.5e^{-45\theta^2} + 1.2e^{-0.7(v_x-v_{\text{cmd}})^2} - 35(y-y_{\text{ref}})^2 - 3\theta^2 - c_u\|\mathbf{u}\|_2^2 - 0.001\|\ddot{x}, \ddot{y}, \ddot{\theta}\|_2^2 + r_{\text{mode}} + r_{\text{sat}} + r_{\text{fail}}. \quad (83)$$

其中 c_u 为动作二范数惩罚权重， r_{mode} 为不同动作模式附加的奖励项， r_{sat} 为动作接近饱和时的惩罚项， r_{fail} 为触发安全终止时的惩罚项。残差类动作 $c_u = 0.03$ ，直接力矩动作 $c_u = 0.008$ 。直接力矩模式额外加入

$$r_{\text{mode}} = -0.004 \sum_{i=1}^3 \left(\frac{\tau_i}{\tau_{i,\text{max}}} \right)^2, \quad (84)$$

其余模式 $r_{\text{mode}} = 0$ 。若任一动作满足 $|u_i| > 0.98$ ，则 $r_{\text{sat}} = -0.5$ ，否则为零；若触发安全终止，则 $r_{\text{fail}} = -50$ ，否则为零。

6.3 PD 残差 PPO

PD 残差模式先由稳定基线控制器计算基础力矩，再叠加 PPO 输出的有限幅值残差。基础控制器的期望加速度为

$$a_{x,\text{cmd}} = 3(v_{\text{cmd}} - v_x) - \frac{\hat{F}_{\text{ext}}}{m}, \quad (85)$$

$$a_{y,\text{cmd}} = 70(y_{\text{ref}} - y) - 16v_y, \quad (86)$$

$$\alpha_{\text{cmd}} = -85\theta - 18\omega. \quad (87)$$

轮毂力矩为

$$\tau_{\text{wheel}} = r(c_x v_{\text{cmd}} + m a_{x,\text{cmd}}), \quad (88)$$

腿部支撑力为

$$F_{\text{leg}} = \max\{m(g + a_{y,\text{cmd}}), 0\}. \quad (89)$$

俯仰任务所需关节力矩满足

$$\begin{bmatrix} 1 & 0.6 \\ 0.15 & 1 \end{bmatrix} \begin{bmatrix} \tau_{\text{knee}} \\ \tau_{\text{hip}} \end{bmatrix} = \begin{bmatrix} dF_{\text{leg}} \\ I\alpha_{\text{cmd}} + k_{\theta}\theta + c_{\theta}\omega - \gamma \max(y, 0.1) \frac{\tau_{\text{wheel}}}{r} \end{bmatrix}. \quad (90)$$

PPO 输出按残差尺度 $\mathbf{s}_{\text{res}} = [5, 25, 25]^T$ 叠加：

$$\boldsymbol{\tau} = \text{clip}(\boldsymbol{\tau}_{\text{base}} + \mathbf{u} \odot \mathbf{s}_{\text{res}}, -\boldsymbol{\tau}_{\text{max}}, \boldsymbol{\tau}_{\text{max}}). \quad (91)$$

6.4 前馈残差 PPO

前馈残差模式使用地形模型计算名义前馈力矩，再由 PPO 输出残差。代码首先计算

$$l_{\text{nom}} = y_{\text{ref}} - h(x) - r, \quad (92)$$

$$\dot{l}_{\text{nom}} = -h'(x)v_{\text{cmd}}, \quad (93)$$

$$F_t^* = c_x v_{\text{cmd}} + mgh'(x) - \hat{F}_{\text{ext}}, \quad (94)$$

$$F_n^* = mg. \quad (95)$$

被动支撑力为

$$F_{\text{pass}}^* = k_l(l_0 - l_{\text{nom}}) - c_l \dot{l}_{\text{nom}}, \quad (96)$$

主动支撑力为

$$F_{\text{act}}^* = F_n^* - F_{\text{pass}}^*. \quad (97)$$

名义轮毂力矩和髋力矩由

$$\tau_{\text{wheel}}^* = r F_t^*, \quad (98)$$

$$\begin{bmatrix} 1 & 0.6 \\ 0.15 & 1 \end{bmatrix} \begin{bmatrix} \tau_{\text{knee}}^* \\ \tau_{\text{hip}}^* \end{bmatrix} = \begin{bmatrix} dF_{\text{act}}^* \\ -\gamma \max(y_{\text{ref}} - h(x), 0.1) F_t^* \end{bmatrix} \quad (99)$$

得到。最终动作映射与残差模式相同：

$$\boldsymbol{\tau} = \text{clip}(\boldsymbol{\tau}_{\text{ff}} + \mathbf{u} \odot \mathbf{s}_{\text{res}}, -\boldsymbol{\tau}_{\text{max}}, \boldsymbol{\tau}_{\text{max}}). \quad (100)$$

6.5 直接力矩 PPO

直接力矩 PPO 不叠加基础控制器，直接把三维动作映射为三路力矩：

$$\tau_{\text{wheel}} = u_1 \tau_{\text{wheel,max}} = 30u_1, \quad (101)$$

$$\tau_{\text{knee}} = \frac{u_2 + 1}{2} \tau_{\text{knee,max}} = 80(u_2 + 1), \quad (102)$$

$$\tau_{\text{hip}} = u_3 \tau_{\text{hip,max}} = 120u_3. \quad (103)$$

膝关节通道映射到 $[0, 160]$ N m，轮毂和髋关节通道映射到对称区间。三路力矩随后仍经过统一限幅函数。该设计把膝关节视为主要伸腿支撑执行器，给直接 PPO 引入了不同于 LQR、WBC/QP 和残差 PPO 的动作先验；因此本文把直接 PPO 结果解释为当前动作空间设计下的经验表现，而不把它视为与其它控制律完全等价的公平算法比较。

6.6 训练配置

训练脚本使用 Stable-Baselines3 的 PPO。本文用于主比较的三种 PPO 均采用同一受控训练协议：random_full 随机场景采样器、 1.5×10^6 步、8 个并行环境、seed 0、学

习率 2×10^{-4} 、熵系数 0.003、归一化动作二次惩罚系数 0.03。直接力矩 PPO 在该受控比较中不再使用额外的直接力矩正则项。公共超参数为

$$n_{\text{steps}} = 1024, \quad \text{batch size} = 256, \quad \gamma = 0.99, \quad \lambda_{\text{GAE}} = 0.95, \quad \epsilon_{\text{clip}} = 0.2. \quad (104)$$

其中 λ_{GAE} 为广义优势估计参数, ϵ_{clip} 为 PPO 概率比裁剪范围。固定场景评估时, 控制器通过 `model.predict(obs, deterministic=True)` 调用训练好的策略。上述设置使 PPO 主比较中的训练预算和主要优化超参数保持一致; 剩余差异主要来自动作映射、基础控制器结构以及动作到物理力矩的尺度。若要进一步形成统计结论, 还需要至少 3–5 个随机种子。

7 固定场景与数据来源

7.1 八个主固定场景

为覆盖题目中的速度范围、地形起伏和水平外力扰动, 本文设计了八个主固定测试场景, 如下表: 场景 A 至 D 分别考察瞬态外力、持续外力、规则地形、平滑随机地形和大幅不规则地形等单一因素; 场景 E 用于复合压力测试; 场景 F 和 G 分别检验 5 m/s 高速跟踪以及最高速度、最大外力、不平地形同时出现时的边界工况。

表 2: 固定测试场景

场景	指令速度	水平外力	地形
A: 瞬态强冲击	2 m/s	$t = 5 \text{ s}$ 时施加 100 N, 持续 0.1 s	平地
B: 持续恒定推力	3 m/s	持续 80 N	平地
C1: 规则正弦地形	2 m/s	无	振幅 0.05 m、波长 1.0 m
C2: 平滑随机地形	2 m/s	无	振幅参数 0.04 m、固定随机种子 7
D: 大幅不规则地形	2 m/s	无	三频正弦叠加, 最大绝对高度约 0.085 m
E: 超规格组合压力	3 m/s	持续 60 N, $t = 4 \text{ s}$ 叠加 100 N 脉冲, 峰值 160 N	三频正弦叠加, 最大绝对高度约 0.090 m
F: 高速平地	5 m/s	无	平地
G: 边界组合	5 m/s	持续 100 N	振幅 0.05 m、波长 1.0 m

表中速度为稳态目标值; 当前代码通过 `smooth_speed` 在约 1 s 内从零平滑上升到目标速度, 因此速度 RMSE 包含启动过程。其中 C2 只使用固定随机种子 7, 不能代表随机地形统计分布; 它应理解为一个平滑随机地形样例。

7.2 数据来源与图表说明

主比较采用目录 `outputs/compare_five_controlled_ppo_1500k` 中的结果：五种实现、八个场景，共 40 条轨迹。`derived_metrics.csv` 由逐采样点日志后处理得到，包含稳态速度 RMSE、分通道饱和比例、平顺性代理量和控制量代理量。静止抗扰分析采用 `outputs/static_push_controlled_ppo_1500k` 中的数据。

PPO 训练使用 `random_full` 采样器时，速度范围为 0 m/s–5 m/s，地形在平地、正弦、多频和噪声地形中随机，外力在无扰动、脉冲和恒定扰动中随机，幅值大体限制在题目范围内。本文只采用单随机种子模型，未用多模型统计均值和标准差；因此固定测试结果不能声称严格泛化性能证明。

8 总体结果与有效性分析

8.1 八场景汇总

表 3: 五种实现的八个主场景平均结果

控制器	未终止	高度 RMSE/m	姿态 RMSE/°	速度 RMSE (m/s)	稳态速度 RMSE (m/s)	饱和比例	$J_s/10^3$	$E_\tau/10^5$
LQR	8/8	0.0273	0.390	0.552	0.358	0.001	14.21	1.596
WBC/QP	8/8	0.00038	0.0095	0.258	0.136	0.019	1.49	1.604
PD 残差 PPO	8/8	0.0108	0.233	0.428	0.263	0.001	13.16	1.565
前馈残差 PPO	8/8	0.0092	2.466	2.053	2.052	0.020	12.18	1.682
直接 PPO	8/8	0.0043	0.259	6.572	7.288	0.000	20.48	1.199

注：数值为八条确定性轨迹的算术平均；稳态速度 RMSE 按 $t \geq 2\text{ s}$ 统计。 J_s 和 E_τ 为代理指标，只用于同一仿真数据集内部比较。

表 3 汇总了八个主固定场景的平均指标。五种实现均未触发安全终止阈值，但任务指标差异较大。WBC/QP 的平均高度 RMSE 为 0.000 38 m，平均姿态 RMSE 为 0.0095°，主要反映其在目标函数中对平台高度和躯干姿态赋予了较高权重，并且与前向仿真共享降阶模型和地形信息。在同一受控训练协议下，PD 残差 PPO 的平均速度 RMSE 为 0.428 m/s，姿态 RMSE 为 0.233°；前馈残差 PPO 的平均速度 RMSE 为 2.053 m/s，表明仅依靠当前前馈残差策略难以在全部场景中维持速度跟踪。直接 PPO 的高度和姿态误差不大，但平均速度 RMSE 达到 6.572 m/s，说明直接力矩输出在当前奖励和动作尺度下没有学到有效速度跟踪。

场景 E 的峰值外力为 160 N，超出题目给定的 100 N 上限，因此表 4 把题目范围内七场景和包含 E 的八主场景分开列出。两种平均方式不改变主要排序，但报告后文把 E 仅作为超规格压力测试解释。

表 5 显示，整体饱和比例主要由膝关节通道贡献，髋关节通道在该数据集中几乎不触及 0.98 倍限幅。因此单一平均饱和比例只能作为粗指标；定位执行器瓶颈时应使用分通道统计。

表 4: 题目范围内主场景与超规格场景的平均速度指标

控制器	八主场景 速度 RMSE	题目范围内七场景 速度 RMSE	说明
LQR	0.552	0.548	E 场景影响较小
WBC/QP	0.258	0.266	E 中速度误差略低于平均
PD 残差 PPO	0.428	0.427	E 场景影响较小
前馈残差 PPO	2.053	1.938	超规格 E 不改变其速度偏差结论
直接 PPO	6.572	6.882	主要问题来自速度跟踪不足

表 5: 八个主场景平均分通道饱和比例

控制器	轮毂通道	膝关节通道	髋关节通道
LQR	0.0030	0	0
WBC/QP	0.0047	0.0524	0
PD 残差 PPO	0	0.0028	0
前馈残差 PPO	0.0022	0.0581	0
直接 PPO	0	0	0

8.2 PPO 受控训练协议比较

表 6 单独列出三种 PPO 在主比较中的结果。三者使用相同的训练分布、训练步数、并行环境数、随机种子、学习率、熵系数和归一化动作惩罚；因此该表主要比较动作映射和基础控制器结构的影响。

表 6: 三种 PPO 的受控训练协议结果

控制器	未终止	高度 RMSE m	姿态 RMSE °	速度 RMSE (m/s)	稳态速度 RMSE (m/s)	饱和比例
PD 残差 PPO	8/8	0.0108	0.233	0.428	0.263	0.0009
前馈残差 PPO	8/8	0.0092	2.466	2.053	2.052	0.0201
直接 PPO	8/8	0.0043	0.259	6.572	7.288	0

表 6 显示，PD 残差 PPO 在三种 PPO 中给出最低速度误差和最低姿态误差；前馈残差 PPO 的速度误差显著变大，说明基础反馈项对学习策略承担稳定和速度任务都很重要。直接 PPO 的高度 RMSE 最低且没有触及力矩饱和，但速度 RMSE 明显偏大；从控制量角度看，它更像是在当前惩罚权重下学到了保守的低能量策略，而不是有效的高速跟踪策略。由于三种动作到物理力矩的尺度仍不同，表中结论应理解为当前动作映射设计的受控实验结果，而不是对所有直接力矩 PPO 形式的否定。

图 2 对应表 6 的受控协议数据。第 9 节的五控制器分场景图同样来自表 3 的主比较数据。




图 2: 受控 PPO 协议下的代表性对照曲线

9 分场景结果分析

本节表格列出五种控制器。叠加图的四个子图自上而下分别为高度误差、躯干俯仰角、水平速度和力矩范数；这些曲线用于观察误差出现的时间位置、扰动后的恢复过程以及控制量变化。表格给出全时域统计量，用于和曲线中的局部现象对应。

9.1 场景 A：瞬态强冲击

表 7: 场景 A 五控制器结果

控制器	状态	$RMSE_h/m$	$e_{h,max}/m$	$RMSE_\theta$	θ_{max}	$RMSE_v/m/s$	饱和比
LQR	未终止	0.01313	0.04522	0.1834°	0.5509°	0.2772	0
WBC/QP	未终止	$< 10^{-5}$	$< 10^{-5}$	$< 10^{-4}^\circ$	$< 10^{-4}^\circ$	0.1367	0
PD 残差 PPO	未终止	0.00093	0.00310	0.0226°	0.0700°	0.2116	0
前馈残差 PPO	未终止	0.00295	0.00501	0.5389°	0.8277°	0.7877	0
直接 PPO	未终止	0.00234	0.00524	0.1660°	0.4645°	7.4612	0

图 3 用同一坐标系比较五种控制器在瞬态水平冲击下的响应。图中 $t = 5s$ 处的外力脉冲主要对应速度和力矩范数的短时变化；高度误差曲线中较大的下沉出现在启动加速阶段，而不是脉冲施加时刻。图 4 进一步单独列出 LQR 与直接 PPO，便于查看两者在高度、速度和姿态通道上的差异。

结合表 7，五种控制器均未终止且未出现力矩饱和。WBC/QP 的高度和姿态误差低于表格有效精度，平地条件下平台通道基本由模型配平。WBC/QP 的速度 RMSE 为 $0.1367m/s$ ，低于 LQR 的 $0.2772m/s$ 和 PD 残差 PPO 的 $0.2116m/s$ 。PD 残差 PPO 的高度 RMSE 为 $0.00093m$ ，姿态 RMSE 为 0.0226° ，比前馈残差和直接 PPO 更平衡。直




图 3: 场景 A 的五控制器叠加曲线。冲击发生在 $t = 5$ s；启动阶段对高度和速度误差的贡献大于短脉冲本身。

接 PPO 的姿态误差不大，但速度 RMSE 达到 7.4612 m/s，说明该受控训练策略没有完成速度跟踪。




图 4: 场景 A 的单控制器曲线。

9.2 场景 B: 持续恒定推力

表 8: 场景 B 五控制器结果

控制器	状态	$RMSE_h/m$	$e_{h,max}/m$	$RMSE_\theta$	θ_{max}	$RMSE_v/m/s$	饱和比
LQR	未终止	0.03297	0.03696	0.6128°	0.7267°	0.7162	0
WBC/QP	未终止	$< 10^{-5}$	$< 10^{-5}$	$< 10^{-4}^\circ$	$< 10^{-4}^\circ$	0.1947	0
PD 残差 PPO	未终止	0.00175	0.00259	0.0555°	0.0619°	0.5142	0
前馈残差 PPO	未终止	0.01698	0.02495	5.1980°	10.0726°	3.7231	0
直接 PPO	未终止	0.00239	0.00578	0.4324°	0.4756°	2.7948	0

图 5 展示了持续 80 N 水平推力作用下的全时域响应。速度子图中，LQR、前馈残差 PPO 和直接 PPO 均出现持续速度偏差；WBC/QP 的速度曲线更接近指令速度。图 6 把 LQR 和 WBC/QP 单独列出，用于对比持续外力下的偏置响应与平台通道保持情况。

表 8 中，LQR 的速度 RMSE 为 0.7162 m/s，对应图中长期低于指令速度的曲线。WBC/QP 的速度 RMSE 降至 0.1947 m/s，同时高度和姿态误差仍接近数值精度；这与其速度积分项和平台任务权重有关。PD 残差 PPO 的速度 RMSE 为 0.5142 m/s，姿态 RMSE 为 0.0555° 。直接 PPO 的姿态 RMSE 为 0.4324° ，但速度 RMSE 为 2.7948 m/s。前馈残差 PPO 的速度 RMSE 达到 3.7231 m/s，是该场景中最明显的速度失控案例。该场景主要区分了控制器对持续水平扰动的速度补偿能力。





图 5: 场景 B 的五控制器叠加曲线。前馈残差方案虽未触发姿态和高度阈值，但速度持续偏离指令。



(a) LQR: 存在持续偏差

(b) WBC/QP: 平台通道接近名义值

图 6: 场景 B 的代表性单控制器曲线。

9.3 场景 C1：规则正弦地形

表 9：场景 C1 五控制器结果

控制器	状态	RMSE _h /m	$e_{h,max}$ /m	RMSE _θ	θ _{max}	RMSE _v /m/s	饱和比
LQR	未终止	0.03514	0.11996	0.3373°	0.9355°	0.5637	0
WBC/QP	未终止	0.00020	0.00067	0.0056°	0.0125°	0.1630	0.0291
PD 残差 PPO	未终止	0.02473	0.10427	0.4264°	1.8211°	0.4810	0
前馈残差 PPO	未终止	0.00966	0.02499	1.7960°	4.7914°	0.7706	0.0308
直接 PPO	未终止	0.00223	0.00479	0.1890°	0.7494°	7.7708	0




图 7：场景 C1 的五控制器叠加曲线。周期地形导致 LQR、两种残差方案和直接 PPO 出现不同幅值的周期响应。

图 7 对应规则正弦地形，四个子图中的高度误差、速度和力矩范数均呈现明显周期成分。这些周期成分来自轮心沿正弦地形运动时的腿长变化和接触力变化。图 8 单独比较 WBC/QP 与直接 PPO，用于观察地形预瞄控制和学习控制在同一地形上的响应差别。

表 9 显示，WBC/QP 的高度 RMSE 为 0.000 20 m，最大高度误差为 0.000 67 m，姿态 RMSE 为 0.0056°；其力矩饱和比例为 2.91%，图中也能看到力矩范数随地形周期波

动。WBC/QP 的速度 RMSE 为 0.1630 m/s，低于其他控制器；直接 PPO 的速度 RMSE 则达到 7.7708 m/s。LQR 不显式使用地形信息，高度 RMSE 为 0.035 14 m，最大高度误差达到 0.119 96 m，这与图中周期性高度误差相对应。PD 残差 PPO 的速度 RMSE 为 0.4810 m/s，前馈残差 PPO 为 0.7706 m/s；两者都明显优于直接 PPO 的速度跟踪。




图 8: 场景 C1 的代表性单控制器曲线。

9.4 场景 C2: 平滑随机地形

表 10: 场景 C2 五控制器结果

控制器	状态	RMSE _h /m	$e_{h,max}$ /m	RMSE _θ	θ _{max}	RMSE _v /m/s	饱和比
LQR	未终止	0.01669	0.04316	0.1770°	0.5280°	0.2650	0
WBC/QP	未终止	2.48×10^{-5}	6.09×10^{-5}	0.0001°	0.0004°	0.1345	0
PD 残差 PPO	未终止	0.00269	0.00621	0.0257°	0.0738°	0.2026	0
前馈残差 PPO	未终止	0.00246	0.00476	0.5167°	0.9323°	0.7798	0
直接 PPO	未终止	0.00400	0.01186	0.1772°	0.4900°	7.4853	0

图 9 给出平滑随机地形下的五控制器响应。与 C1 的规则周期地形不同，该图中的高度误差和力矩范数没有固定周期，曲线变化主要由固定随机地形的局部坡度决定。图中红色前馈残差曲线在速度通道仍有明显偏差，其余控制器的速度曲线则较快进入接近指令速度的区间。

表 10 中，WBC/QP 的高度 RMSE 为 2.48×10^{-5} m，最大高度误差为 6.09×10^{-5} m，姿态 RMSE 为 0.0001°，平台通道误差低于其他方法。PD 残差 PPO 的速度 RMSE 为 0.2026 m/s，同时姿态 RMSE 仅为 0.0257°。LQR 的高度 RMSE 为 0.016 69 m，速度 RMSE 为 0.2650 m/s；PD 残差 PPO 的高度 RMSE 为 0.002 69 m，速度 RMSE 为 0.2026 m/s。与 C1 相比，本固定随机地形的坡度变化更缓，因此多数控制器的高度误差和速度误差整体较小。前馈残差 PPO 的速度 RMSE 为 0.7798 m/s，直接 PPO 为 7.4853 m/s，说明直接力矩策略的速度问题不是由单个地形频率造成的。




图 9: 场景 C2 的五控制器叠加曲线。该固定随机地形经平滑后局部变化较缓。

9.5 场景 D: 大幅不规则地形

表 11: 场景 D 五控制器结果

控制器	状态	RMSE _h /m	$e_{h,max}$ /m	RMSE _θ	θ _{max}	RMSE _v /m/s	饱和比
LQR	未终止	0.01225	0.03674	0.1302°	0.4014°	0.2672	0
WBC/QP	未终止	0.00014	0.00037	0.0053°	0.0114°	0.1349	0.0166
PD 残差 PPO	未终止	0.00426	0.00865	0.0401°	0.1175°	0.2311	0
前馈残差 PPO	未终止	0.00414	0.01045	0.6810°	2.1695°	0.7825	0.0229
直接 PPO	未终止	0.00357	0.01013	0.2216°	0.6953°	7.6015	0

图 10 对应三频叠加的大幅不规则地形。高度误差和力矩范数不再呈单一周期，在局部起伏较大的位置出现更密集的力矩变化。图 11 单独列出 WBC/QP 与直接 PPO，用于比较两者在高度跟踪、速度跟踪和姿态角变化上的分配。

表 11 中，WBC/QP 的高度 RMSE 为 0.00014 m，姿态 RMSE 为 0.0053°，速度 RMSE 为 0.1349 m/s，饱和比例为 1.66%；该场景中 WBC/QP 的最大摩擦利用率为 0.7385，接




图 10: 场景 D 的五控制器叠加曲线。多频地形使力矩范数呈非周期变化。

触约束已经参与控制分配。PD 残差 PPO 的速度 RMSE 为 0.2311 m/s，高度 RMSE 为 0.00426 m。前馈残差 PPO 的速度 RMSE 为 0.7825 m/s，直接 PPO 为 7.6015 m/s。从图和表同时看，WBC/QP 主要压低平台误差和速度误差，PD 残差 PPO 在该地形上给出次优速度表现。




图 11: 场景 D 的代表性单控制器曲线。

9.6 场景 E: 超规格组合压力

表 12: 场景 E 五控制器结果

控制器	状态	RMSE _h /m	$e_{h,max}$ /m	RMSE _θ	θ _{max}	RMSE _v /m/s	饱和比
LQR	未终止	0.02780	0.04651	0.4906°	0.6991°	0.5833	0
WBC/QP	未终止	0.00019	0.00054	0.0117°	0.0207°	0.1996	0.0162
PD 残差 PPO	未终止	0.00333	0.00799	0.0452°	0.1253°	0.4291	0.0033
前馈残差 PPO	未终止	0.01370	0.02360	3.1587°	6.4487°	2.8575	0.0487
直接 PPO	未终止	0.00731	0.01488	0.3123°	0.6423°	4.4003	0

图 12 给出组合压力场景下的五控制器叠加响应。该场景同时包含不规则地形、持续外力和 100 N 脉冲，外力峰值达到 160 N。图中的红色前馈残差曲线在速度通道持续偏离，其高度和姿态仍未超过终止阈值；这说明“未终止”和“速度跟踪良好”在该场景中需要分开判断。图 13 单独给出 WBC/QP 与直接 PPO，便于观察两种代表性控制器在平台通道和速度通道上的差异。

表 12 中，WBC/QP 的高度 RMSE 为 0.00019 m，姿态 RMSE 为 0.0117°，速度 RMSE 为 0.1996 m/s，饱和比例为 1.62%。PD 残差 PPO 的速度 RMSE 为 0.4291 m/s，LQR 为 0.5833 m/s，前馈残差 PPO 为 2.8575 m/s。直接 PPO 的姿态 RMSE 为 0.3123°，但速度 RMSE 为 4.4003 m/s。该场景超出题目外力上限，因此它在本文中用于观察组合扰动下的响应形态，而不作为题目范围内的性能边界。

图 14 为场景 E 的 WBC/QP 诊断图，分别给出接触力与摩擦边界、实际腿长与预测腿长、约束残差/松弛量、摩擦利用率和求解状态。对应的诊断数据中，最大摩擦利用率为 0.7507，QP 与 OSQP 状态均为 100% 成功，最大等式残差约 1.14×10^{-13} ，不等式违反量为零。平均 OSQP 求解耗时约 0.078 ms，最大约 1.31 ms。这些数值对应当前电脑、当前轨迹和当前降阶模型下的求解记录。




图 12: 场景 E 的五控制器叠加曲线。该场景峰值外力为 160 N, 超出题目上限。




图 13: 场景 E 的代表性单控制器曲线。




图 14: 场景 E 的 WBC/QP 诊断图: 接触力与摩擦边界、实际与预测腿长、残差与松弛量、摩擦利用率和求解状态。

9.7 场景 F: 5 m/s 高速平地

表 13: 场景 F 五控制器结果

控制器	状态	RMSE _h /m	e _{h,max} /m	RMSE _θ	θ _{max}	RMSE _v /m/s	饱和比
LQR	未终止	0.03179	0.11163	0.3699°	1.1325°	0.6686	0
WBC/QP	未终止	0.00206	0.00723	0.0394°	0.1394°	0.7114	0.0633
PD 残差 PPO	未终止	0.02835	0.11909	0.6897°	3.0193°	0.5531	0.0004
前馈残差 PPO	未终止	0.00546	0.00907	0.5274°	1.4384°	2.3060	0
直接 PPO	未终止	0.00221	0.00404	0.1513°	0.4160°	10.2279	0




图 15: 场景 F 的五控制器叠加曲线。速度 RMSE 包含从初始速度到 5 m/s 的完整启动过程。

图 15 给出 5 m/s 高速平地场景的响应。速度子图包含从静止到目标速度的启动段，因此全时域速度 RMSE 同时记录加速过程和接近稳态后的偏差。高度误差和力矩范数的峰值主要集中在启动初期，该阶段也是不同控制器差异最明显的位置。

表 13 中，PD 残差 PPO 的速度 RMSE 为 0.5531 m/s，略低于 LQR 的 0.6686 m/s 和 WBC/QP 的 0.7114 m/s。WBC/QP 的高度 RMSE 为 0.00206 m，姿态 RMSE 为

0.0394°，在平台通道上保持较小误差；其饱和比例为 6.33%。直接 PPO 的高度 RMSE 为 0.002 21 m，姿态 RMSE 为 0.1513°，但速度 RMSE 达到 10.2279 m/s。前馈残差 PPO 的速度 RMSE 为 2.3060 m/s。LQR 的最大高度误差达到 0.111 63 m，对应图中启动阶段的明显下沉。高速场景中，速度响应和平台姿态之间的分配差异比中低速场景更突出。

9.8 场景 G：题目边界组合

表 14: 场景 G 五控制器结果

控制器	状态	RMSE _h /m	e _{h,max} /m	RMSE _θ	θ _{max}	RMSE _v /m/s	饱和比
LQR	未终止	0.04882	0.10259	0.8212°	0.9484°	1.0754	0.0079
WBC/QP	未终止	0.00043	0.00189	0.0141°	0.0332°	0.3882	0.0270
PD 残差 PPO	未终止	0.02059	0.09016	0.5590°	2.3240°	0.7982	0.0037
前馈残差 PPO	未终止	0.01794	0.02734	7.3124°	15.0027°	4.4138	0.0583
直接 PPO	未终止	0.00999	0.01657	0.4204°	0.8344°	4.8313	0




图 16: 场景 G 的五控制器叠加曲线。该场景同时达到题目规定的速度和外力上限。

图 16 对应题目边界组合场景，速度为 5 m/s，水平外力为 100 N，地形为规则正弦起

伏。该图同时显示高速启动、持续推力和地形周期扰动对四个通道的影响。图 17 单独列出 WBC/QP 与直接 PPO：前者的高度和姿态曲线接近零线，后者在该受控协议下速度偏差明显。

表 14 中，WBC/QP 的高度 RMSE 为 0.00043m，姿态 RMSE 为 0.0141°，速度 RMSE 为 0.3882m/s，饱和比例为 2.70%。PD 残差 PPO 的速度 RMSE 为 0.7982m/s，姿态 RMSE 为 0.5590°。前馈残差 PPO 与直接 PPO 的速度 RMSE 分别为 4.4138m/s 和 4.8313m/s。在最高速度、最大外力和不平地形同时出现时，表格和曲线显示 WBC/QP 仍保持平台高度、姿态和速度指标的综合优势。




图 17: 场景 G 的代表性单控制器曲线。

9.9 场景 H: 0m/s 静止抗扰

为覆盖题目速度范围下端，本文设置两组 0m/s 平地静止抗扰场景：H0 为 $t = 4s$ 施加 100N、持续 0.1s 的水平脉冲；H1 为全程持续 100N 水平外力。两组场景采用同一组控制器和安全判据。

表 15: 0m/s 静止抗扰结果

场景	控制器	状态	$RMSE_h/m$	$RMSE_\theta$	$RMSE_v/m/s$	饱和比
H0 脉冲	LQR	未终止	0.00164	0.0244°	0.0372	0
H0 脉冲	WBC/QP	未终止	$< 10^{-5}$	$< 10^{-4}^\circ$	0.0227	0
H0 脉冲	PD 残差 PPO	未终止	0.00037	0.0861°	0.0490	0
H0 脉冲	前馈残差 PPO	未终止	0.00075	0.3911°	0.1139	0
H0 脉冲	直接 PPO	未终止	0.00454	0.3814°	5.5199	0
H1 持续	LQR	未终止	0.04331	0.8728°	0.9578	0
H1 持续	WBC/QP	未终止	$< 10^{-5}$	$< 10^{-4}^\circ$	0.1579	0
H1 持续	PD 残差 PPO	未终止	0.00184	0.0706°	0.6851	0
H1 持续	前馈残差 PPO	未终止	0.01672	4.5706°	5.4310	0
H1 持续	直接 PPO	未终止	0.04677	1.9220°	4.2173	0

表 15 表明，0m/s 脉冲场景下五种控制器均可维持粗安全条件；持续 100N 外力下，WBC/QP 的速度偏差较小，LQR 因缺少外力估计和积分出现明显稳态偏差，前馈残差

PPO 和直接 PPO 则出现严重速度跑偏。该结果仍是确定性检查，不能替代多扰动时刻、多方向外力和多随机种子的统计评估。

10 控制器比较与实现改进

10.1 LQR

LQR 适合作为可解释、低计算量的基线。当前实现的主要不足不是算法本身，而是设计点和增广状态不足：无外力估计、无积分、无地形调度，且线性化含不可微裁剪。可依次改进为：去掉绝对位置模态；加入速度积分构成 LQI；使用扰动观测器；按速度和坡度进行增益调度；最后再比较带输入约束的 MPC。

10.2 降阶 WBC/QP

在当前二维降阶模型、精确地形可用、无参数失配、无观测噪声和无控制时延的条件下，WBC/QP 能直接表达任务权重、摩擦和执行器约束，适合作为平台稳定优先任务的主控制器候选。进一步改进应优先验证：

- 对质量、惯量、摩擦、地形高度和坡度误差做参数扫描；
- 把 $F_n \geq 0.35mg$ 的经验下界改为可解释的接触安全裕度，并做灵敏度分析；
- 将单步预瞄扩展为多步 MPC，避免高曲率地形下的局部近似误差；
- 复用 OSQP 工作区并统计完整控制周期，而非只统计求解器调用；
- 在高保真多刚体模型中验证主动支撑力映射和俯仰耦合系数。

10.3 残差 PPO 与直接 PPO

PD 残差 PPO 训练较容易，并且在受控协议下给出三种 PPO 中最好的速度与姿态折中；前馈残差消融说明，去掉基础反馈后，当前策略难以可靠承担全部稳定任务。直接 PPO 的高度和姿态误差不大，但速度跟踪明显不足，说明直接力矩动作空间仍需要更合适的奖励、动作尺度或安全过滤设计。部署前需要多随机种子训练、域随机化、观测噪声与时延训练、动作变化率限制，并在策略输出后增加 QP 安全过滤器或备用控制器。

10.4 推荐方案

对题目中“速度跟踪、躯干竖直、地形扰动和水平外力”同时存在的任务，本文推荐以降阶 WBC/QP 为主控制器，理由是其任务优先级与约束可显式解释，并在边界场景 G 中给出最小高度、姿态误差和最低速度误差。PD 残差 PPO 可作为学习策略对照；在当前证据下，直接 PPO 尚未作为速度补偿或安全关键主控制器使用。LQR 保留为基线和故障回退方案。

11 复现方式与代码核验清单

11.1 依赖安装

项目依赖由 requirements.txt 管理。在项目根目录执行：

```
python -m pip install -r requirements.txt
```

11.2 建议的统一评估命令

```
python -B scripts/run_compare.py \  
  --controllers lqr wbc_qp rl_ppo rl_ppo_feedforward rl_ppo_direct \  
  --residual-model-path outputs/models/  
    ppo_wheel_leg_residual_random_1500k_n8_seed0_controlled \  
  --feedforward-model-path outputs/models/  
    ppo_wheel_leg_feedforward_residual_random_1500k_n8_seed0_controlled \  
  --direct-model-path outputs/models/  
    ppo_wheel_leg_direct_random_1500k_n8_seed0_controlled \  
  --out-dir outputs/compare_five_controlled_ppo_1500k  
  
python -B scripts/build_derived_metrics.py \  
  --metrics-csv outputs/compare_five_controlled_ppo_1500k/metrics.csv \  
  --logs-dir outputs/compare_five_controlled_ppo_1500k/logs \  
  --out-csv outputs/compare_five_controlled_ppo_1500k/derived_metrics.csv
```

稳态速度 RMSE、分通道饱和比例、平顺性代理量和控制量代理量由 logs/ 后处理得到。主比较和静止抗扰的数据目录分别为 outputs/compare_five_controlled_ppo_1500k 和 outputs/static_push_controlled_ppo_1500k。

11.3 受控 PPO 训练命令

```
python -B scripts/train_rl.py --action-mode residual \  
  --scenario-set random_full --timesteps 1500000 --n-envs 8 \  
  --seed 0 --device cpu --learning-rate 0.0002 --ent-coef 0.003 \  
  --action-cost 0.03 --direct-torque-cost 0.0 \  
  --save-path outputs/models/ppo_wheel_leg_residual_random_1500k_n8_seed0_controlled  
  
python -B scripts/train_rl.py --action-mode feedforward_residual \  
  --scenario-set random_full --timesteps 1500000 --n-envs 8 \  
  --seed 0 --device cpu --learning-rate 0.0002 --ent-coef 0.003 \  
  --action-cost 0.03 --direct-torque-cost 0.0 \  
  --save-path outputs/models/  
    ppo_wheel_leg_feedforward_residual_random_1500k_n8_seed0_controlled  
  
python -B scripts/train_rl.py --action-mode direct \  
  --scenario-set random_full --timesteps 1500000 --n-envs 8 \  
  --seed 0 --device cpu --learning-rate 0.0002 --ent-coef 0.003
```

```
--seed 0 --device cpu --learning-rate 0.0002 --ent-coef 0.003 \
--action-cost 0.03 --direct-torque-cost 0.0 \
--save-path outputs/models/ppo_wheel_leg_direct_random_1500k_n8_seed0_controlled
```

11.4 静止抗扰与回归测试入口

```
python -B scripts/run_compare.py --scenario-set static_push \
--controllers lqr wbc_qp rl_ppo rl_ppo_feedforward rl_ppo_direct \
--residual-model-path outputs/models/
ppo_wheel_leg_residual_random_1500k_n8_seed0_controlled \
--feedforward-model-path outputs/models/
ppo_wheel_leg_feedforward_residual_random_1500k_n8_seed0_controlled \
--direct-model-path outputs/models/
ppo_wheel_leg_direct_random_1500k_n8_seed0_controlled \
--out-dir outputs/static_push_controlled_ppo_1500k

python -B -m unittest discover -s tests -v
```

11.5 主要源码映射

表 16: 报告内容与源码文件对应关系

文件	作用
src/config/params.py	机器人参数、仿真参数和安全阈值
src/config/scenarios.py	八个主固定测试场景、速度平滑和外力函数
src/config/random_scenarios.py	PPO 随机训练场景采样器
src/model/terrain.py	平地、正弦、多频和噪声地形
src/model/kinematics.py	轮心高度、腿长、逆运动学和 RL 观测量
src/model/dynamics.py	前向动力学、RK4 积分、失败检测和 WBC 仿射模型
src/controllers/base.py	控制器接口、平衡力矩、残差动作和直接动作映射
src/controllers/lqr.py	数值线性化、CARE 求解和 LQR 控制律
src/controllers/wbc_qp.py	降阶 WBC/QP 的目标、约束、OSQP 求解与诊断量
src/controllers/rl_policy.py	PPO 模型加载、残差/前馈/直接策略适配器
src/rl/env.py	Gymnasium 环境、奖励函数和训练终止逻辑
src/simulation/runner.py	统一仿真循环、盲扰动开关和日志采样
src/evaluation/metrics.py	指标计算和 CSV 输出
src/evaluation/plots.py	单控制器图、叠加对比图和 WBC 诊断图
scripts/build_derived_metrics.py	从逐采样点日志生成稳态速度、分通道饱和、平顺性和控制量派生指标
tests/test_core_logic.py	动力学、场景、日志和题目边界的回归测试

12 结论

本文在统一二维降阶平台上比较了 LQR、降阶 WBC/QP 和三种 PPO 结构。结果支持以下结论：

1. 五种实现均未触发当前安全终止阈值，但前馈残差 PPO 的严重速度偏差说明安全成功率不能替代任务性能指标。
2. WBC/QP 在高度和姿态指标上最优，尤其适合平台稳定优先的任务；其极小误差受到共享精确模型和地形预瞄条件的显著影响。
3. 在相同训练预算、学习率、熵系数和动作惩罚下，PD 残差 PPO 给出三种 PPO 中较好的速度与姿态折中；直接 PPO 虽然高度和姿态误差较小，但平均速度 RMSE 达到 6.572 m/s，说明当前直接力矩动作空间和奖励尺度不足以可靠完成速度跟踪。
4. LQR 作为基线稳定可靠，但缺少积分、扰动估计和地形适应时，持续外力与高速组合工况下速度误差较大。
5. 0 m/s 静止抗扰检查支持主实验趋势，但本文实验仍是确定性课程仿真比较，不是实机稳定性证明。下一步应加入多随机种子、参数失配、传感器噪声、时延、接触切换和高保真多刚体模型。

从题目目标出发，推荐采用 WBC/QP 作为主要控制器，并把 LQR 用作简洁基线，把 PPO 用作策略结构对照。该结论只对当前模型、权重、限幅、八个主测试场景和两组 0 m/s 静止场景成立。

参考文献

- [1] M. Bjelonic, R. Grandia, P. Fankhauser, O. Harley, C. D. Bellicoso, and M. Hutter. Keep Rollin'—Whole-Body Motion Control and Planning for Wheeled Quadrupedal Robots. *IEEE Robotics and Automation Letters*, 4(2):2116–2123, 2019.
- [2] R. E. Kalman. Contributions to the theory of optimal control. *Boletín de la Sociedad Matemática Mexicana*, 5:102–119, 1960.
- [3] B. D. O. Anderson and J. B. Moore. *Optimal Control: Linear Quadratic Methods*. Prentice Hall, 1990.
- [4] O. Khatib. A unified approach for motion and force control of robot manipulators: The operational space formulation. *IEEE Journal on Robotics and Automation*, RA-3(1):43–53, 1987.
- [5] B. Stellato, G. Banjac, P. Goulart, A. Bemporad, and S. Boyd. OSQP: an operator splitting solver for quadratic programs. *Mathematical Programming Computation*, 12:637–672, 2020. <https://web.stanford.edu/~boyd/papers/osqp.html>

- [6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal Policy Optimization Algorithms. arXiv:1707.06347, 2017. <https://arxiv.org/abs/1707.06347>
- [7] M. Towers et al. Gymnasium: A Standard Interface for Reinforcement Learning Environments. arXiv:2407.17032, 2024. <https://arxiv.org/abs/2407.17032>
- [8] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, and N. Dormann. Stable-Baselines3: Reliable Reinforcement Learning Implementations. *Journal of Machine Learning Research*, 22(268):1–8, 2021. <https://jmlr.org/papers/v22/20-1364.html>